
Análisis de Tendencias en Videos de YouTube Usando el Conjunto de Datos “Trending YouTube Video Statistics”

Joel Rodriguez Sosa
Instituto Politécnico Nacional
joel30rs@gmail.com

Danae Cadena Lima
Instituto Politécnico Nacional
danacadena07@gmail.com

Abstract

En este reporte presentamos el análisis exploratorio y descriptivo de nuestro conjunto de datos Trending Youtube Video Statistics que obtuvimos en Kaggle, este contiene información diaria sobre los videos que aparecen en la lista de tendencias en YouTube para múltiples países. Nuestro objetivo principal es poder identificar patrones de vistas, likes, comentarios, tendencias por categoría y características asociadas con videos que alcanzan mayor popularidad. Se aplicaron técnicas de preprocesamiento, análisis estadístico y visualización de datos para comprender las dinámicas de contenido popular en la plataforma.

1 Introducción

YouTube es un sitio web y una aplicación donde los usuarios pueden subir, ver y compartir videos sobre diversos temas. Esta plataforma de medios sociales permite a los creadores conectar con su público y ofrece una serie de funciones para ayudarles a hacer crecer sus canales y monetizar su contenido. Se enfoca en que las y los usuarios sean quienes creen el contenido audiovisual de la plataforma e interactúen entre sí. Como empresa de medios digitales, YouTube gestiona una de las mayores plataformas de video online del mundo y genera ingresos a través de la publicidad y otros métodos de monetización. Al ser una de las plataformas de video más influyentes a nivel mundial el conjunto de datos nos proporciona métricas clave como el número de vistas, likes, dislikes, comentarios y metadatos de videos que han sido tendencia en distintos países, así podemos comprender los factores que determinan la viralidad puede ayudar a creadores de contenido y expertos en marketing digital a optimizar estrategias de publicación.

2 Trabajo Relacionado

El conjunto de datos ha sido utilizado en diversos proyectos de análisis de datos y machine learning con el objetivo de comprender y poder predecir tendencias de videos. Una clara referencia son aquellos trabajos en donde se han realizado análisis exploratorios para correlacionar vistas con otras métricas como likes y comentarios, así como intentos de modelar estas relaciones usando regresión lineal y clasificadores. También se han explorado enfoques de análisis de sentimiento y procesamiento de lenguaje natural sobre descripciones y etiquetas de videos.

3 Metodología y Desarrollo

3.1 Descripción del conjunto de datos

Se incluyen registros diarios de los videos que aparecen en la página de tendencias de YouTube. Para cada video registrado, se cuenta con varias columnas como el identificador único del video, título, nombre del canal, fecha en la que se volvió tendencia, fecha y hora de publicación, categoría del contenido, vistas, likes, dislikes, número de comentarios, metadatos (tags, descripción), el conjunto se encuentra dividido por país y cada uno esta en un archivo CSV separado.

3.2 Preprocesamiento

Nuestro preprocesamiento de los datos se baso en: 1. Recolección de los datos 2. Exploración inicial 3. Limpieza de datos 4. Transformación de los datos 5. Visualización de datos y estadísticos

3.3 Análisis exploratorio

Distribuciones de vistas: Se observan diferencias en las métricas de vistas, likes y comentarios entre categorías de video, lo que permite identificar los géneros con mayor interacción. Tendencias temporales: Los datos permiten analizar no solo qué videos se vuelven tendencia, sino cuánto tiempo permanecen en la lista y con qué rapidez alcanzan altos números de vistas. Relaciones entre variables: Se pueden calcular correlaciones entre el número de vistas y otras métricas como likes y comentarios para entender mejor qué factores se asocian a videos virales.

4 Experimentos y Resultados

4.1 Estructura del conjunto de datos

Antes de realizar las visualizaciones, se realizó una inspección técnica del conjunto para asegurar la validez de los resultados:

Dimensiones del Dataset: El conjunto de datos inicial consta de 16 columnas y un aproximado de 40,949 registros por archivo.

Integridad de los Datos: Se verificó que la mayoría de las variables críticas (como video id, trending date, views y likes) cuentan con 40,949 valores no nulos.

Valores Faltantes: La columna description es la única que presenta una ligera ausencia de datos.

Tipos de Datos: Se identificó que las métricas de interacción (views, likes, dislikes, comment count) están almacenadas como enteros de 64 bits, mientras que las fechas de tendencia (trending date) fueron correctamente convertidas al formato datetime64[ns] para facilitar el análisis temporal.

4.2 Procesamiento y Partición Temporal

Para entender la evolución de las tendencias, se aplicaron técnicas de agregación de datos:

Extracción de Medias Mensuales: Se generó una partición de datos por mes y año (month year) para calcular las medias de visualizaciones por video.

Ejemplo de Variabilidad: En una muestra de noviembre de 2017, se observó una alta dispersión en el rendimiento de los videos; mientras que algunos promediaron 695 vistas, otros en el mismo periodo alcanzaron promedios de 546,297 vistas, lo que justifica el uso de escalas logarítmicas para el análisis de distribución.

Estado de los Videos: La inspección visual nos confirmó que, en el momento de la captura, los videos analizados no presentaban errores de carga ni habían sido eliminados (video error or removed: False), garantizando que los resultados reflejan contenido activo en la plataforma.

4.3 Resultados

En nuestros primeros resultados basandonos sobre las categorías que dominan las tendencias, promedio de vistas y los días que tarda un video en volverse tendencia son los siguientes:




Figure 1: Días que tarda un video en volverse tendencia

Podemos observar que de 3 a 4 días son los que mayormente tardan en volverse tendencia los videos, y son pocos los que tardan más de 15 días.




Figure 2: Categorías en tendencia

En el puesto número uno tenemos entretenimiento, seguido por musica y estilo , en el último puesto estan los shows.




Figure 3: Vistas por categoría

En nuestro primer puesto tenemos de igual forma a musica que marca una gran diferencia (el doble) sobre todas las demás.

5 Conclusiones

El análisis nos revela que los videos que alcanzan tendencias en YouTube exhiben patrones claros de alta interacción (vistas, likes y comentarios). Las categorías específicas como música o entretenimiento dominan las listas de trending, lo que sugiere que ciertos tipos de contenido tienen más probabilidad de viralizar dentro de la plataforma. El dataset provee una valiosa fuente para estudiar el comportamiento de los usuarios y las dinámicas de popularidad en plataformas sociales.

6 Referencias

manualpandas2024, title = pandas: powerful Python data analysis toolkit, author = The pandas development team, year = 2024, url = <https://pandas.pydata.org/>

articlehunter2007matplotlib, author = Hunter, J. D., title = Matplotlib: A 2D graphics environment, journal = Computing in Science & Engineering, volume = 9, number = 3, pages = 90–95, year = 2007

softwarewaskom2021seaborn, author = Michael Waskom, title = mwaskom/seaborn: v0.11.2 (August 2021), year = 2021, publisher = Zenodo, doi = 10.5281/zenodo.5231034

misckaggleYoutube, author = Mitchell J., title = YouTube Trending Video Dataset (USA), year = 2023, note = Dataset extraído de Kaggle, url = <https://www.kaggle.com/datasets/datasnaek/youtube-new>