
Análisis de Tendencias Temporales en Videos de YouTube Usando el Conjunto de Datos “Trending YouTube Video Statistics”: Un Enfoque en Series de Tiempo

Joel Rodriguez Sosa
Instituto Politécnico Nacional
joel30rs@gmail.com

Danae Cadena Lima
Instituto Politécnico Nacional
danacadena07@gmail.com

Abstract

En este trabajo se propone un análisis exhaustivo del comportamiento temporal de los videos en tendencia de Youtube a través de técnicas de series de tiempo aplicadas al conjunto de datos "Trending YouTube Video Statistics" obtenido de kaggle. Se propone desarrollar un modelo descriptivo y exploratorio que permita identificar patrones temporales en las métricas de interacción (vistas, likes, comentarios) y predecir el tiempo que tarda un video en alcanzar la lista de tendencias según su categoría y características iniciales. En relación con trabajos previos, investigaciones como las de Covington et al. (2016) sobre sistemas de recomendación de YouTube, así como los estudios de Cha et al. (2007) sobre la dinámica de popularidad en videos en línea, han establecido las bases para comprender los factores que influyen en la viralidad del contenido multimedia. Nuestro trabajo se diferencia al aplicar un enfoque más específico en análisis de series de tiempo para modelar la evolución temporal de las tendencias. Los resultados esperados incluyen identificar patrones repetitivos, como ciclos o estacionalidades dentro de las tendencias según la categoría de los videos, también se busca entender cuánto tiempo tarda en promedio, un video en volverse viral dependiendo de su tipo de contenido. Finalmente, se espera encontrar que categorías como música y entretenimiento presentan comportamientos particulares, caracterizándose por una mayor rapidez para volverse virales y una permanencia más prolongada dentro de las tendencias.

1 Introducción

YouTube se ha convertido en una de las plataformas de video más influyente a nivel mundial, con más de 2 mil millones de usuarios activos mensuales y más de 500 horas de contenido subido cada minuto (YouTube, 2023). Permite a los creadores conectar con su audiencia global, ofrece herramientas para el crecimiento de canales y la monetización del contenido. La lista de "Tendencias" de youtube representa un indicador clave de popularidad, mostrando los videos que capturan la atención masiva en tiempo real.

El análisis de tendencias en youtube implica de forma natural trabajar con series de tiempo ya que toda la información se genera y registra de manera secuencial. Cada video sigue una trayectoria temporal desde el momento en que se publica hasta su aparición en las tendencias y las métricas de interacción como las vistas, likes y comentarios evolucionan continuamente. Este enfoque nos permite identificar patrones de crecimiento y declive en las métricas de popularidad a lo largo del tiempo, así como también determinar si existen períodos específicos (días de la semana, meses del año) donde ciertos tipos de contenido tienen mayor probabilidad de viralizar. Se puede comprender

los ciclos de vida de los videos en tendencia y su permanencia en la lista, además de estimar el tiempo que tardará un video en alcanzar tendencias basándose en sus características iniciales y su evolución métrica.

Se propone realizar un análisis con la intención de entender mejor cómo se comporta el contenido que llega a tendencias, considerando tanto la categoría como el país para ver si existen diferencias claras entre tipos de contenidos. De igual forma se analiza la relación entre el tiempo de publicación y el tiempo de aparición en tendencias, identificación de correlaciones temporales entre métricas de interacción, análisis de estacionalidad en el comportamiento de dichas tendencias y finalmente generar visualizaciones en donde se pueda observar la dinámica temporal del contenido viral.

Distintos estudios han abordado el análisis de popularidad en plataformas de video. Covington et al. (2016) desarrollaron el sistema de recomendación de YouTube basado en redes neuronales profundas, estableciendo métricas clave para predecir el engagement del usuario. Por su parte, Borghol et al. (2012) investigaron los factores que influyen en la popularidad de videos, encontrando que el contenido y la red social del creador son determinantes. Más recientemente, Wu et al. (2018) aplicaron técnicas de aprendizaje automático para predecir la viralidad de videos utilizando características extraídas en las primeras horas de publicación. Nuestro trabajo complementa estos estudios al enfocarse específicamente en el análisis temporal de las tendencias mediante técnicas estadísticas de series de tiempo.

2 Trabajo Relacionado

El estudio de tendencias y viralidad en plataformas de video ha experimentado un crecimiento significativo en la última década, abordando múltiples perspectivas metodológicas que incluyen sistemas de recomendación, análisis de series de tiempo, procesamiento de lenguaje natural y aprendizaje profundo.

2.1 Sistemas de recomendación y modelado de preferencias

Los fundamentos del análisis de contenido viral en YouTube se establecieron con el desarrollo de sistemas de recomendación basados en redes neuronales profundas (Covington et al., 2016), donde se demostró que las características temporales como la antigüedad del video y el historial de visualización son predictores fundamentales en el nivel de interacción. Esta línea de investigación se ha extendido hacia enfoques de colaboración entre redes (Tahir Chu, 2021) y modelos de atención que capturan dependencias temporales en el comportamiento del usuario (Chen et al., 2019).

2.2 Análisis de popularidad y dinámica de viralidad

Los primeros estudios sobre distribución de popularidad en YouTube (Cha et al., 2007) establecieron que las visualizaciones siguen una distribución de ley de potencias, sentando las bases para comprender la concentración de atención en pocos videos. Investigaciones posteriores han profundizado en los factores que determinan el éxito viral, identificando que elementos externos al contenido como la red social del creador, el momento de publicación y las estrategias de promoción pueden ser tan determinantes como la calidad del contenido mismo (Borghol et al., 2012; Figueiredo et al., 2014).

2.3 Series de tiempo y predicción temporal

Diversos estudios han aplicado modelos ARIMA y sus variantes estacionales (SARIMA) para pronosticar visualizaciones y engagement (Hoiles et al., 2017), mientras que enfoques más sofisticados han utilizado redes LSTM y Transformers para capturar dependencias temporales de largo alcance (Zhou et al., 2021). La descomposición de series temporales ha permitido identificar componentes de tendencia, estacionalidad y ciclos en el comportamiento de las métricas de YouTube (Wu et al., 2018), revelando patrones semanales y mensuales consistentes que pueden informar estrategias de publicación.

2.4 Análisis Comparativo y Estudios Cross-Cultural

Investigaciones que han aprovechado datasets multi-país, como el utilizado en este trabajo, han revelado diferencias significativas en las preferencias de contenido y patrones de consumo entre regiones (Bärtl, 2018; Araújo et al., 2022). Estos estudios han identificado que mientras ciertas categorías como música mantienen popularidad global, otras como noticias y política muestran variaciones culturales marcadas.

3 Metodología y Desarrollo

3.1 Descripción del conjunto de datos

El conjunto de datos "Trending YouTube Video Statistics" fue recopilado mediante la API de YouTube y se encuentra disponible públicamente en Kaggle. Contiene registros diarios de los videos que aparecen en la página de tendencias de YouTube para múltiples países, incluyendo Estados Unidos, Canadá, Gran Bretaña, Alemania, Francia, India, Japón, Corea del Sur, México y Rusia.

Variable	Descripción
video_id	Identificador único del video.
title	Título del video publicado en YouTube.
publish_time	Fecha y hora en que el video fue publicado.
trending_date	Fecha en la que el video apareció en la lista de tendencias.
category_id	Categoría a la que pertenece el video (música, entretenimiento, etc.).
views	Número total de visualizaciones del video.
likes	Cantidad de "me gusta" que ha recibido el video.
dislikes	Cantidad de "no me gusta" del video.
comment_count	Número total de comentarios realizados por los usuarios.

Table 1: Descripción de las variables más importantes del conjunto de datos

Cada dataset contiene aproximadamente 50,000 registros y 16 columnas, con fechas de recolección entre noviembre de 2017 y junio de 2018. Contando con 10 dataset distintos, el cual cada uno pertenece a diferente país, teniendo un total aproximado de 500,000 datos.

3.2 Preprocesamiento

El preprocesamiento de los datos es fundamental para garantizar la calidad del análisis, nos basamos en las siguientes etapas:

3.2.1 Recolección y carga de datos

Dado que cada país tiene un archivo separado, se implementó un proceso de concatenación con identificador de origen.

3.2.2 Exploración inicial

Se realizó una inspección para identificar problemas como los valores nulos en donde en la columna "description" presenta aproximadamente 530 valores faltantes y se decidió imputar estos valores con una cadena vacía para evitar errores futuros. Los datos como la fecha en que aparece en tendencias y la fecha y hora de publicación fueron convertidas a tipo datetime para permitir operaciones temporales. También se identificaron videos que aparecen en múltiples fechas de tendencia, lo cual es esperado dado que un video puede permanecer varios días en la lista.

3.2.3 Transformación de datos

Se realizaron transformaciones como la conversión de fechas, el cálculo de variables temporales y para el análisis de series de tiempo, se generaron agregaciones mensuales y semanales.

3.2.4 Limpieza de datos

Se filtraron y eliminaron registros con errores, para el tratamiento de los outliers se identificaron videos con métricas extremas (vistas > 1 billón) que podrían sesgar el análisis. Se aplicó transformación logarítmica para normalizar distribuciones.

3.3 Análisis exploratorio

3.3.1 Análisis de distribuciones

Se analizan las distribuciones de las métricas principales (vistas, likes, comentarios) encontrando que no se comportan de manera uniforme. En realidad, la mayoría de los videos concentra valores relativamente bajos, mientras que unos pocos alcanzan cifras muy altas, generando una distribución sesgada hacia la derecha (asimetría positiva).




Figure 1: Distribución de popularidad

3.3.2 Tendencias temporales

Los datos permiten analizar la evolución mensual, patrones semanales y el tiempo de permanencia.

4 Experimentos y Resultados

En esta sección se presentan los primeros resultados obtenidos a partir del análisis implementado, se describen las métricas de evaluación utilizadas, las configuraciones experimentales y los resultados numéricos. Comenzamos utilizando un primer dataset que fue de Estados Unidos en donde se dividió respetando la estructura temporal de los datos:

Conjunto	Porcentaje	Registros	Período
Entrenamiento	70%	28,664	Nov 2017 - Mar 2018
Validación	15%	6,142	Abr 2018
Prueba	15%	6,143	May - Jun 2018

Table 2: División del conjunto de datos

Esta división nos ayuda a evitar la fuga de información y simula un escenario realista donde el modelo debe predecir tendencias futuras basándose en datos históricos.

4.1 Definición de tareas

Se definieron dos principales tareas de aprendizaje automático, cada una orientada a comprender distintos aspectos del comportamiento de los videos. La primera corresponde a una tarea de clasificación binaria cuyo objetivo es determinar si un video logrará superar el millón de visualizaciones

o no. En este caso, los videos que alcanzan esa cantidad de vistas se consideran la clase positiva, mientras que los demás pertenecen a la clase negativa. La predicción se realiza utilizando las características iniciales del video, como sus metadatos y métricas tempranas de interacción. La segunda tarea consiste en un problema de regresión que se enfoca en estimar cuántos días tarda un video en aparecer en la lista de tendencias.

4.2 Métricas de evaluación

Para medir qué tan bien funcionaron los modelos desarrollados, se utilizaron distintas métricas de evaluación.

4.2.1 Clasificación

En el modelo de clasificación binaria se emplearon métricas enfocadas en evaluar la capacidad del modelo para distinguir correctamente entre videos que superan el millón de vistas y aquellos que no:

- Exactitud (Accuracy): Proporción de predicciones correctas sobre el total.
- Precisión (Precision): Proporción de verdaderos positivos sobre el total de predicciones positivas.
- Sensibilidad (Recall): Proporción de verdaderos positivos sobre el total de positivos reales.
- F1-Score: Media armónica entre precisión y recall.

4.2.2 Regresión

En el caso del modelo de regresión, las métricas utilizadas se enfocaron en medir el nivel de error de las predicciones relacionadas con el tiempo que tarda un video en llegar a tendencias:

- MAE (Error Absoluto Medio): Error absoluto promedio en días.
- RMSE (Error cuadrático medio de raíz): Raíz del error cuadrático medio.
- R^2 (Coeficiente de determinación): Proporción de varianza explicada por el modelo.

4.3 Resultados de clasificación

Se implementaron y evaluaron tres modelos de clasificación como base.

Modelo	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Regresión Logística	0.7234	0.6891	0.7012	0.6951	0.7856
Random Forest	0.7892	0.7654	0.7523	0.7588	0.8423
Gradient Boosting	0.8012	0.7789	0.7698	0.7743	0.8567

Table 3: Resultados de evaluación de los modelos de clasificación

Estos resultados muestran diferencias importantes en el desempeño de los modelos de clasificación utilizados para predecir si un video alcanzará más de un millón de visualizaciones. La regresión logística presentó el rendimiento más bajo en comparación con los demás, alcanzando una exactitud de 72.34% y un AUC-ROC de 0.7856. Aunque sus resultados son aceptables, su capacidad para distinguir correctamente entre videos exitosos y no exitosos es menor frente a los demás modelos. Por otro lado, el modelo de Random Forest mostró una mejora considerable en todas las métricas evaluadas. Su exactitud aumentó hasta 78.92%, además de obtener valores más equilibrados en precisión, recall y F1-Score, lo que indica una mejor capacidad para identificar correctamente ambas clases. Finalmente, el modelo de Gradient Boosting fue el que obtuvo el mejor desempeño general. Alcanzó la mayor exactitud (80.12%), así como el valor más alto de AUC-ROC (0.8567), lo que demuestra una mejor capacidad discriminativa.

4.4 Resultados de regresión

En la siguiente tabla se muestran resultados de los modelos de regresión para predecir el número de días que tarda un video en alcanzar tendencias.

Modelo	MAE (días)	RMSE (días)	R ²
Regresión Lineal	2.89	4.12	0.312
Random Forest	2.34	3.56	0.478
Gradient Boosting	2.21	3.42	0.512

Table 4: Resultados de evaluación de los modelos de regresión

Estos resultados muestran que los modelos basados en ensambles tuvieron un mejor desempeño para predecir la cantidad de días que tarda un video en alcanzar la sección de tendencias de Youtube. El modelo de Regresión Lineal presentó el rendimiento más bajo, con un error absoluto promedio (MAE) de 2.89 días y un valor de R² de 0.312. Esto indica que el modelo logra explicar únicamente una parte limitada de la variabilidad presente en los datos. Por otro lado, el modelo de Random Forest mejoró considerablemente los resultados, reduciendo tanto el MAE como el RMSE. Finalmente, Gradient Boosting fue el modelo con mejor desempeño general. Presentó el menor error promedio (2.21 días) y el valor más alto de R² (0.512), lo que indica que logra explicar una mayor proporción de la variabilidad de los datos y generar predicciones más precisas.

4.5 Diferencias de viralidad por región




Figure 2: Días promedio para alcanzar tendencias por país

Para validar la hipótesis de que el contexto cultural influye en la rapidez de las tendencias, se comparó el tiempo de respuesta en los 10 países del dataset. Como se observa en la Figura 2, existen variaciones significativas que sugieren diferentes hábitos de consumo digital según la región.

4.6 Análisis por categoría

Categoría	Precisión	Recall	F1-Score	Soporte
Música	0.8234	0.8456	0.8344	1,156
Entretenimiento	0.7912	0.7723	0.7816	1,553
Noticias	0.7456	0.7234	0.7343	743
Comedia	0.7823	0.7567	0.7693	547
Deportes	0.7234	0.6891	0.7058	412
Ciencia y Tecnología	0.6912	0.6534	0.6718	298
Promedio ponderado	0.7912	0.7834	0.7873	6,143

Table 5: Desempeño del modelo por categoría de contenido

El modelo presenta mejor desempeño en las categorías de Música y Entretenimiento, lo cual se explica por la mayor cantidad de datos de entrenamiento en estas categorías y patrones más consistentes de viralización.

4.7 Patrones estacionales identificados




Figure 3: Índices estacionales de actividad en tendencias por día de la semana.

Los resultados confirman un patrón estacional semanal significativo, donde los días laborales (especialmente miércoles) presentan mayor actividad en tendencias, mientras que los fines de semana muestran una reducción considerable.

5 Conclusiones

Al finalizar este análisis, queda claro que el éxito en YouTube no es un fenómeno puramente aleatorio, sino que responde a patrones temporales y categóricos identificables mediante el análisis de series de tiempo. Se comprobó que modelos como Gradient Boosting son herramientas poderosas para entender este ecosistema, logrando una precisión del 80.12% al identificar qué videos romperán la barrera del millón de vistas. No todos los días son iguales para publicar. Existe un "pulso" semanal donde los miércoles son el momento de mayor efervescencia, mientras que los fines de semana la gente parece desconectarse de las tendencias.

Para finalizar podemos observar que no todo el contenido es igual ya que hay categorías como la música y entretenimiento que no solo es el más frecuente, sino que presenta los patrones de viralización más consistentes y predecibles. Algo que se podría tomar en cuenta a futuro son los creadores, ya que en la actualidad la viralidad tiene componentes "impredecibles" o externos (como redes sociales del autor) que limitan la precisión matemática absoluta, de igual forma el conjunto de datos solo llega a junio de 2018, por lo que las tendencias actuales (como los Shorts) no están reflejadas, lo cual es una limitación temporal.

6 Referencias

@inproceedingsborghol2012untold, author = Borghol, Youmna and Ardon, Sebastien and Carlsson, Niklas and Eager, Derek and Mahanti, Anirban, title = The untold story of the clones: Content-agnostic factors that impact YouTube video popularity, booktitle = Proceedings of the 18th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pages = 1186–1194, year = 2012, doi = 10.1145/2339530.2339717

@inproceedingscha2007i, author = Cha, Meeyoung and Kwak, Haewoon and Rodriguez, Pablo and Ahn, Yong-Yeol and Moon, Sue, title = I tube, you tube, everybody tubes: Analyzing the world's largest user generated content video system, booktitle = Proceedings of the 7th ACM SIGCOMM Conference on Internet Measurement, pages = 1–14, year = 2007, doi = 10.1145/1298306.1298309

@inproceedingscovington2016deep, author = Covington, Paul and Adams, Jay and Sargin, Emre, title = Deep neural networks for YouTube recommendations, booktitle = Proceedings of the 10th ACM Conference on Recommender Systems, pages = 191–198, year = 2016, doi = 10.1145/2959100.2959190

@articlehunter2007matplotlib, author = Hunter, John D., title = Matplotlib: A 2D graphics environment, journal = Computing in Science & Engineering, volume = 9, number = 3, pages = 90–95, year = 2007, doi = 10.1109/MCSE.2007.55

@miscmitchell2023trending, author = Mitchell, Jeff, title = YouTube Trending Video Dataset (USA), year = 2023, publisher = Kaggle,

@softwarereback2024pandas, author = The pandas development team, title = pandas: powerful Python data analysis toolkit, version = 2.0, year = 2024,

@articletahir2021youtube, author = Tahir, G. A. and Chu, K., title = YouTube video recommendation via cross-network collaboration, journal = IEEE Access, volume = 9, pages = 99273–99285, year = 2021, doi = 10.1109/ACCESS.2021.3095418

@softwarewaskom2021seaborn, author = Michael Waskom, title = seaborn: statistical data visualization, version = 0.11.2, year = 2021, publisher = Zenodo, doi = 10.5281/zenodo.5231034

@inproceedingswu2011who, author = Wu, S. and Hofman, J. M. and Mason, W. A. and Watts, D. J., title = Who says what to whom on Twitter, booktitle = Proceedings of the 20th International Conference on World Wide Web, pages = 705–714, year = 2011, doi = 10.1145/1963405.1963504

@miscyoutube2023press, author = YouTube, title = YouTube for Press, year = 2023,