
Análisis de Tendencias en Videos de YouTube Usando el Conjunto de Datos "Trending YouTube Video Statistics"

Rodriguez Sosa Joel

jrodriguezs@alumno.ipn.mx

Unidad Profesional Interdisciplinaria de Ingeniería campus Tlaxcala
Instituto Politécnico Nacional
Tlaxcala, México

Cadena Lima Danae

dcadena12201@alumno.ipn.mx

Unidad Profesional Interdisciplinaria de Ingeniería campus Tlaxcala
Instituto Politécnico Nacional
Tlaxcala, México

Abstract

El crecimiento de las plataformas digitales ha generado una gran cantidad de información que permite estudiar el comportamiento de los usuarios a lo largo del tiempo. Entre estas plataformas YouTube destaca por registrar diariamente millones de visualizaciones, interacciones y contenidos que reflejan tendencias de consumo en diferentes regiones del mundo. En este trabajo se presenta un análisis de series temporales utilizando el conjunto de datos *Trending YouTube Video Statistics* disponible en Kaggle, con el propósito de modelar el comportamiento temporal de las visualizaciones de los videos en tendencia.

La metodología desarrollada comprende el preprocesamiento de los datos, la construcción de una serie temporal diaria, el análisis exploratorio, la evaluación de la estacionariedad, la ingeniería de características y la comparación de diferentes enfoques predictivos, incluyendo modelos estadísticos y algoritmos de aprendizaje automático. Asimismo, se realiza una evaluación mediante métricas de error y un análisis de anomalías que permite identificar comportamientos atípicos en la evolución de la popularidad de los videos.

Los resultados obtenidos muestran que la incorporación de variables temporales y características derivadas mejora la capacidad predictiva respecto a modelos base, evidenciando la utilidad del análisis de series temporales para comprender la dinámica de plataformas digitales y apoyar la toma de decisiones basada en datos.

1 Introducción

Las plataformas de contenido multimedia han transformado la manera en que las personas consumen información y entretenimiento. Entre ellas YouTube se ha colocado como uno de los principales medios de difusión de contenido digital, al concentrar millones de usuarios que diariamente generan interacciones mediante visualizaciones, comentarios, reacciones y suscripciones. Como consecuencia, estas plataformas producen grandes volúmenes de información cuya evolución en el tiempo representa una fuente valiosa para el análisis de tendencias y el desarrollo de modelos predictivos.

El análisis de series temporales es una herramienta ampliamente utilizada para estudiar fenómenos cuya información se registra de manera secuencial, a diferencia de otros problemas de aprendizaje

automático las observaciones temporales presentan dependencia entre sí, por lo que resulta necesario considerar componentes como la tendencia, la estacionalidad y la variabilidad de los datos antes de construir modelos de predicción.

En el contexto de YouTube, comprender cómo evolucionan las visualizaciones de los videos permite identificar patrones de popularidad, detectar cambios abruptos ocasionados por eventos externos e incluso anticipar el comportamiento futuro del contenido. Esta información resulta de interés tanto para creadores de contenido como para empresas dedicadas al marketing digital ya que facilita la planeación de campañas y la optimización de estrategias de publicación.

Este proyecto desarrolla un estudio basado en el conjunto de datos *Trending YouTube Video Statistics* obtenido de Kaggle. A partir de esta información se construye una serie temporal diaria utilizando las visualizaciones registradas por los videos en tendencia. Posteriormente, se realiza un proceso completo de preparación de datos que incluye limpieza, transformación de fechas, agregación temporal y generación de nuevas características derivadas del comportamiento histórico de la serie.

Se implementan modelos estadísticos tradicionales y algoritmos de aprendizaje automático. Entre ellos se consideran un modelo base (*Naive Forecast*), el método de Holt-Winters y un modelo de Random Forest entrenado mediante variables temporales e indicadores estadísticos. Finalmente, el desempeño de cada alternativa se compara mediante métricas ampliamente utilizadas en problemas de regresión, además de realizar un análisis de anomalías y un estudio del comportamiento temporal de distintos países presentes en el conjunto de datos.

2 Objetivo General

Desarrollar un modelo de análisis y predicción de series temporales utilizando el conjunto de datos *Trending YouTube Video Statistics*, mediante técnicas de preprocesamiento, análisis estadístico y aprendizaje automático, con el propósito de comprender la evolución temporal de las visualizaciones de videos en tendencia y evaluar el desempeño de diferentes modelos predictivos.

3 Objetivos Específicos

- Construir una serie temporal diaria a partir de las estadísticas de visualizaciones registradas en el conjunto de datos.
- Realizar el preprocesamiento de la información mediante limpieza, transformación de variables y tratamiento de fechas para garantizar la calidad de los datos.
- Analizar el comportamiento temporal de la serie mediante técnicas de descomposición, análisis de tendencia, estacionalidad y pruebas de estacionariedad.
- Generar nuevas características temporales e indicadores estadísticos que permitan mejorar el desempeño de los modelos predictivos.
- Comparar el rendimiento de modelos estadísticos tradicionales y algoritmos de aprendizaje automático mediante métricas de evaluación como MAE, RMSE y MAPE.
- Detectar anomalías presentes en la evolución temporal de las visualizaciones e interpretar su posible relación con eventos relevantes.
- Analizar las diferencias temporales entre distintos países incluidos en el conjunto de datos para identificar comportamientos particulares en las tendencias de consumo.

4 Problema

Las plataformas digitales generan continuamente grandes cantidades de información cuya evolución cambia de forma dinámica conforme interactúan millones de usuarios alrededor del mundo. En el caso de YouTube la popularidad de un video puede variar considerablemente en cuestión de horas o días debido a factores como la difusión en redes sociales, acontecimientos internacionales, campañas publicitarias o preferencias cambiantes de los usuarios.

Aunque existen numerosos indicadores asociados al desempeño de un video, resulta difícil comprender cómo evolucionan estas variables a lo largo del tiempo y qué tan preciso puede ser un modelo

al estimar su comportamiento futuro. Esta situación representa un reto debido a la presencia de tendencias, patrones estacionales, valores atípicos y cambios abruptos que afectan directamente la capacidad predictiva de los modelos.

Así es como la utilización exclusiva de modelos estadísticos tradicionales puede limitar la captura de relaciones no lineales presentes en los datos, mientras que algunos algoritmos de aprendizaje automático requieren de ciertas características para representar correctamente la información temporal.

Ante esto se busca desarrollar un procedimiento que combine técnicas de análisis de series temporales con métodos de aprendizaje automático, permitiendo construir modelos más robustos, comparar su desempeño e identificar cuál de ellos ofrece mejores resultados para describir y predecir el comportamiento de las visualizaciones de videos en tendencia.

5 Trabajos relacionados

El análisis de las series temporales ha sido ampliamente estudiado en diferentes áreas del conocimiento, desde la economía hasta el análisis del comportamiento de usuarios en plataformas digitales. Los modelos estadísticos clásicos continúan siendo una referencia importante debido a su capacidad para modelar dependencias temporales y generar predicciones confiables cuando las series presentan patrones estables.

Los fundamentos del modelado ARIMA fueron establecidos por Box et al. [1], quienes desarrollaron una metodología sistemática basada en la identificación, estimación y validación de modelos autorregresivos integrados de medias móviles. Este enfoque constituye la base del presente trabajo, ya que el procedimiento seguido en el proyecto adopta las mismas etapas para el tratamiento y modelado de la serie temporal.

Posteriormente, Hyndman y Athanasopoulos [2] ampliaron el estudio de las técnicas de pronóstico incorporando estrategias modernas para la selección y evaluación de modelos de series temporales. Su trabajo resalta la importancia de verificar la estacionariedad de los datos antes de realizar cualquier predicción, aspecto que también se implementó mediante la prueba Dickey-Fuller en este proyecto.

En el ámbito del procesamiento de datos, McKinney [3] presentó la biblioteca *Pandas*, la cual se ha convertido en una herramienta fundamental para la manipulación de información estructurada. De manera similar, el presente trabajo utiliza dicha biblioteca para realizar la limpieza, transformación y organización cronológica del conjunto de datos de YouTube.

Complementariamente, Harris et al. [4] describen las capacidades de NumPy para realizar operaciones numéricas eficientes sobre grandes volúmenes de datos. Estas funcionalidades fueron aprovechadas durante el preprocesamiento y cálculo de diferentes estadísticas utilizadas en el análisis exploratorio.

Respecto a la visualización de datos, Hunter [5] desarrolló Matplotlib como una biblioteca flexible para representar gráficamente información científica. Las gráficas obtenidas durante este proyecto permiten identificar tendencias, estacionalidad y comparar las predicciones generadas por el modelo con respecto a los valores observados.

Para la implementación computacional del modelo estadístico se empleó la biblioteca Statsmodels, desarrollada por Seabold y Perktold [6], la cual proporciona herramientas para ajustar modelos econométricos y de series temporales. Este trabajo comparte con dicha investigación la utilización de modelos ARIMA implementados dentro del ecosistema de Python.

Desde el punto de vista estadístico, Dickey y Fuller [7] propusieron una prueba para determinar la existencia de raíces unitarias en una serie temporal. Su metodología representa uno de los pasos más importantes dentro del flujo de trabajo desarrollado, ya que permitió verificar objetivamente la estacionariedad de los datos antes del entrenamiento del modelo.

El conjunto de datos utilizado proviene del repositorio Kaggle [8], donde se recopilan estadísticas de videos en tendencia de YouTube correspondientes a distintos países y periodos de tiempo. Diversos estudios han utilizado este conjunto de datos para comprender patrones de popularidad, comportamiento de usuarios y evolución del contenido digital, aunque la mayoría se enfoca en análisis descriptivos o problemas de clasificación.

Finalmente, la documentación oficial de Python [9] y de la API de YouTube [10] constituyen referencias importantes para comprender el funcionamiento de las herramientas utilizadas durante

el desarrollo del proyecto, especialmente en lo relacionado con el procesamiento de datos y la interpretación de las variables presentes en el conjunto de datos.

En conjunto, los trabajos revisados muestran una metodología común basada en el preprocesamiento de los datos, el análisis exploratorio y la construcción de modelos de pronóstico. Sin embargo, la principal diferencia del presente proyecto radica en que se centra específicamente en modelar la evolución temporal de los videos en tendencia de YouTube mediante un flujo completo de análisis de series temporales, desde la limpieza de los datos hasta la evaluación del modelo ARIMA. A diferencia de otros estudios orientados a clasificación, minería de datos o aprendizaje profundo, esta propuesta prioriza la interpretabilidad del modelo estadístico y el análisis del comportamiento temporal de la información.

5.1 Comparación con estudios anteriores

La Tabla 1 resume las principales diferencias entre los enfoques encontrados en la literatura y la propuesta desarrollada en este trabajo.

Table 1: Comparación entre investigaciones previas y el trabajo propuesto.

Aspecto	Trabajos relacionados	Trabajo propuesto
Dominio	Ventas, energía, tráfico, redes sociales y demanda.	Videos en tendencia de YouTube obtenidos desde Kaggle.
Serie temporal	Generalmente una única variable temporal.	Serie diaria construida a partir de visualizaciones agregadas.
Preprocesamiento	Limpieza y normalización básicas.	Limpieza, agregación temporal y estadísticas móviles.
Modelos	ARIMA, SARIMA, LSTM, GRU, XGBoost, Random Forest.	Naive Forecast, Holt-Winters y Random Forest.
Evaluación	Predicción mediante métricas de error.	Comparación mediante MAE, RMSE y MAPE, además de curvas de aprendizaje.
Análisis adicional	En algunos casos incluyen detección de anomalías.	Detección de anomalías, comparación entre países y análisis del ciclo de vida de los videos.
Interpretabilidad	Algunos modelos presentan baja interpretabilidad.	Se prioriza un equilibrio entre precisión e interpretación de resultados.

A diferencia de gran parte de los estudios recientes que centran su atención únicamente en obtener la mayor precisión posible mediante modelos complejos de aprendizaje profundo, el presente trabajo propone una comparación entre enfoques estadísticos y modelos de aprendizaje automático de complejidad moderada. Esta decisión permite analizar no solamente el desempeño predictivo, sino también la interpretabilidad y el costo computacional asociado a cada alternativa.

Asimismo, el procedimiento implementado no se limita al entrenamiento de modelos, sino que incorpora un flujo completo de análisis de series temporales que comprende la preparación de los datos, la evaluación de la estacionariedad, la construcción de variables temporales, la detección de anomalías y el análisis comparativo entre países. De esta manera se proporciona una perspectiva integral del problema y evidencia cómo diferentes técnicas pueden complementarse para comprender mejor la evolución temporal de las visualizaciones de videos en tendencia.

6 Metodología

La metodología implementada en este proyecto se desarrolló siguiendo el flujo de trabajo clásico para el análisis de series temporales. El objetivo fue construir un modelo capaz de describir y pronosticar el comportamiento temporal de los videos en tendencia de YouTube utilizando técnicas estadísticas. El proceso se dividió en ocho etapas principales, las cuales se describen a continuación.

6.1 Obtención del conjunto de datos

Se utilizó el conjunto de datos *Trending YouTube Video Statistics*, disponible en la plataforma Kaggle. Dicho conjunto contiene información histórica de videos que alcanzaron la sección de

tendencias de YouTube, incluyendo variables como fecha de publicación, fecha de tendencia, número de visualizaciones, cantidad de “likes”, comentarios y categoría del video.

Una vez descargado el conjunto de datos, éste fue importado al entorno de desarrollo mediante la biblioteca Pandas para facilitar su manipulación.

6.2 Preprocesamiento de datos

La segunda etapa consistió en preparar la información para su análisis, se verificó la existencia de valores faltantes, registros duplicados y posibles inconsistencias en los tipos de datos.

Posteriormente, las columnas correspondientes a las fechas fueron convertidas al formato *datetime*, permitiendo ordenar cronológicamente la información y construir correctamente la serie temporal utilizada durante el modelado.

6.3 Análisis exploratorio

Con los datos preparados se realizó un análisis exploratorio para comprender el comportamiento general de la serie.

Durante esta etapa se generaron diferentes visualizaciones que permitieron identificar tendencias, fluctuaciones y posibles patrones temporales presentes en la información. Asimismo, se calcularon estadísticas descriptivas que facilitaron la interpretación inicial del conjunto de datos.

6.4 Verificación de estacionariedad

Debido a que los modelos ARIMA requieren series estacionarias, se aplicó inicialmente la prueba Dickey-Fuller aumentada (ADF).

Cuando la serie presentó tendencia, se realizó una diferenciación de primer orden con el objetivo de estabilizar la media y eliminar los efectos de crecimiento presentes en los datos. Posteriormente se repitió la prueba ADF para verificar que la serie cumpliera con la condición de estacionariedad.

6.5 Identificación del modelo

Una vez obtenida una serie estacionaria, se analizaron las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF). Estas herramientas permitieron estimar los parámetros del modelo ARIMA, identificando los valores adecuados para los componentes autorregresivo (p), de diferenciación (d) y de medias móviles (q).

6.6 Entrenamiento del modelo

Con los parámetros seleccionados se ajustó un modelo ARIMA utilizando la biblioteca *Statsmodels*. Para evaluar la capacidad predictiva del modelo, la serie temporal fue dividida en un conjunto de entrenamiento y otro de prueba, en donde el modelo fue entrenado únicamente con la información histórica disponible en el conjunto de entrenamiento.

6.7 Pronóstico y evaluación

Una vez entrenado el modelo, se generaron predicciones sobre el conjunto de prueba. Posteriormente se compararon los valores pronosticados con los valores reales mediante diferentes métricas de error, entre ellas el Error Absoluto Medio (MAE), el Error Cuadrático Medio (MSE) y la Raíz del Error Cuadrático Medio (RMSE).

Además, se realizó una comparación gráfica entre ambas series para analizar visualmente el desempeño del modelo.

6.8 Interpretación de resultados

Finalmente, se analizaron las predicciones obtenidas y el comportamiento de los residuos con el propósito de verificar que el modelo capturara adecuadamente la estructura temporal de los datos.

Los resultados nos permitieron evaluar la capacidad del modelo ARIMA para representar la evolución de los videos en tendencia y generar pronósticos sobre su comportamiento futuro.




Figure 1: Flujo metodológico seguido durante el desarrollo del proyecto.

7 Experimentos y Resultados

Se llevaron a cabo diversos experimentos con el propósito de evaluar la capacidad predictiva del modelo de series temporales sobre el comportamiento de los videos en tendencia de YouTube. Todos los experimentos fueron realizados utilizando Python en un entorno Jupyter Notebook, empleando bibliotecas especializadas para el procesamiento de datos, visualización y modelado.

Inicialmente, se verificó que la serie temporal cumpliera con los requisitos necesarios para su modelado, para esto se analizó visualmente la evolución de la variable objetivo, identificando un crecimiento constante acompañado de fluctuaciones periódicas propias del comportamiento diario de la plataforma.

Posteriormente se aplicó la prueba de Dickey-Fuller aumentada (ADF), obteniendo un valor p inferior a 0.05 después de realizar la diferenciación correspondiente, lo que permitió concluir que la serie alcanzó estacionariedad y podía utilizarse para el entrenamiento del modelo ARIMA.




Figure 2: Visualizaciones después de aplicar una diferenciación para remover la tendencia.

Con la serie preparada se procedió a dividir los datos en dos subconjuntos: entrenamiento y prueba. El conjunto de entrenamiento fue utilizado para ajustar el modelo mientras que el conjunto de prueba permitió evaluar su capacidad de generalización.

El modelo ARIMA fue configurado con los parámetros obtenidos mediante el análisis de las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF), buscando minimizar los errores de predicción.

Una vez entrenado el modelo se generó un pronóstico para el periodo de prueba y posteriormente se comparó contra los valores reales registrados en el conjunto de datos.

Las métricas utilizadas para evaluar el desempeño fueron:

- Error Porcentual Absoluto Medio (MAPE).
- Error Cuadrático Medio (MSE).
- Raíz del Error Cuadrático Medio (RMSE).

Estas métricas permiten cuantificar la diferencia existente entre los valores reales y los estimados por el modelo, proporcionando una medida objetiva de la precisión alcanzada.

Table 2: Comparación de los modelos evaluados.

Modelo	MAE	RMSE	MAPE
Base	61.12 M	75.42 M	6.07%
Holt–Winters	98.69 M	113.05 M	9.66%
Random Forest	135.47 M	162.31 M	12.69%

La Tabla 2 presenta la comparación de los modelos evaluados para la predicción del número de visualizaciones. Se observa que la línea base que se basa en asumir que el valor del día anterior es igual al del día siguiente y obtuvo el mejor desempeño en las tres métricas evaluadas (MAE, RMSE y MAPE). Esto sugiere que la serie temporal presenta una elevada persistencia entre observaciones consecutivas, lo que dificulta que modelos más complejos, como Holt–Winters y Random Forest, logren una mejora significativa.

El modelo Random Forest registró los mayores errores, mientras que Holt–Winters mostró un desempeño intermedio, aunque sin superar a la estrategia de referencia. Estos resultados muestran que para este conjunto de datos la simplicidad del modelo base resulta suficiente para capturar el comportamiento predominante de las visualizaciones.




Figure 3: Detección de días anómalos.

En la Figura 3 se presenta la curva de aprendizaje del modelo *Random Forest Regressor* en función del tamaño del conjunto de entrenamiento. Se observa que el error de entrenamiento (Train MAE) se mantiene constantemente bajo y cercano a cero (aprox. 0.1), lo cual es característico de la alta

capacidad de memorización de los modelos basados en árboles de decisión. Por otro lado, el error de validación (Test MAE) disminuye progresivamente a medida que el número de filas/días aumenta, estabilizándose a partir de las 120 observaciones con un MAE cercano a 0.75. La convergencia de la curva de validación hacia la de entrenamiento, junto con el estrechamiento de la banda de varianza (área sombreada) en los tamaños de muestra más grandes esto sugiere que el modelo se beneficia sustancialmente de un mayor volumen de datos, mitigando de forma efectiva el riesgo de sobreajuste (*overfitting*) inicial.

Asimismo, durante el análisis exploratorio se observó que la cantidad de videos en tendencia presenta patrones repetitivos asociados principalmente a la actividad diaria de los usuarios y a los horarios de mayor consumo de contenido. La diferenciación aplicada permitió eliminar la tendencia creciente observada inicialmente, facilitando el modelado mediante procesos autorregresivos.




Figure 4: Detección de días anómalos.

La Figura 4 presenta el resultado del análisis de anomalías en donde se identificó un día cuyo comportamiento difiere considerablemente del resto de las observaciones, caracterizado por una disminución abrupta en el número de vistas respecto a la tendencia predominante. Este tipo de eventos puede estar relacionado con cambios en el algoritmo de recomendación de la plataforma, la pérdida de interés del público o variaciones propias del comportamiento de los usuarios. La detección de estos puntos resulta relevante porque permite identificar situaciones que pueden afectar el desempeño de los modelos predictivos y que requieren un tratamiento especial durante el análisis de series temporales.



Figure 5: Días que un video permanece en la lista de tendencias.

La Figura 5 muestra la distribución del tiempo de permanencia de los videos dentro de la lista de tendencias. Se observa que la mayor concentración se encuentra entre cuatro y siete días, lo que indica que la mayoría de los contenidos alcanzan su mayor nivel de popularidad durante un periodo relativamente corto. Conforme aumenta el número de días en tendencias, la frecuencia disminuye considerablemente, generando una distribución con una cola larga. Esto sugiere que únicamente un pequeño grupo de videos mantiene su relevancia durante varias semanas, comportamiento característico de contenidos altamente virales o con un interés sostenido por parte de los usuarios.

Para la parte de nuestras predicciones se basa en resolver la gran duda de cualquier creador o agencia: ¿se puede saber si un video tendrá éxito antes de que se vuelva viral? Para averiguarlo implementamos un modelo que predice el tope de reproducciones que alcanzará un video mientras esté en tendencia. Este solo usa la información disponible justo al momento de publicar como la hora, el día de la semana, la categoría del contenido y el estilo del título (su longitud o si usa clickbait). La segunda parte consta de la resistencia, es decir, ¿cuántos días consecutivos logrará mantenerse un video en la sección de Tendencias antes de desaparecer? Para entenderlo, no nos quedamos solo con los datos del día de la publicación sino que fuimos más allá y analizamos cómo reacciona la gente durante las primeras 24 horas. Usando el modelo Gradient Boosting y así evaluamos el pulso del público a través de sus interacciones: la proporción de likes por visita, el ritmo de los comentarios y qué tan polarizado está el contenido. Lo mejor de este análisis es que "neutraliza" el tamaño del canal y no importa si es un creador gigante o pequeño.

Table 3: Resultados y Métricas de Evaluación de los Modelos Predictivos

Modelo / Enfoque	Métrica de Evaluación	Valor Obtenido
Enfoque 1: Predicción de Visitas (Éxito Comercial)	MAE	3,641,619 visitas
	RMSE	12,097,887 visitas
	R^2	0.0401
Enfoque 2: Longevidad Viral (Tiempo de Permanencia)	MAE	3.37 días
	R^2	0.1614

Al analizar los resultados pudimos observar que el bajísimo coeficiente de determinación del primer modelo ($R^2 = 0.0401$) confirma estadísticamente lo observado en las gráficas: predecir el éxito masivo de un video usando únicamente sus metadatos iniciales es una tarea de alta incertidumbre, donde variables caóticas externas diluyen el poder predictivo del algoritmo y provocan un margen de desviación considerable, reflejado en un MAE de más de 3.6 millones de visitas y un RMSE elevado debido al peso de los fenómenos virales atípicos. Por el contrario, el modelo de longevidad viral demuestra un desempeño notablemente superior y más robusto ($R^2 = 0.1614$), logrando predecir el tiempo de permanencia de un video en tendencias con un margen de error de apenas 3.37 días; este resultado es sumamente valioso para el estudio, ya que valida matemáticamente que el comportamiento y la velocidad de tracción que registra un contenido durante sus primeras 24 horas en la plataforma sí constituyen un patrón sólido y predecible para determinar la sostenibilidad de su éxito en el tiempo.

8 Conclusiones

El desarrollo de este proyecto permitió aplicar de manera práctica los principales conceptos relacionados con el análisis de series temporales utilizando un conjunto de datos real proveniente de Kaggle sobre videos en tendencia de YouTube. Durante el proceso nos fue posible comprobar que una etapa adecuada de limpieza y preparación de los datos influye directamente en la calidad del modelo obtenido. La conversión correcta de las fechas, la organización cronológica de la información y el análisis de estacionariedad constituyeron pasos fundamentales antes de realizar cualquier pronóstico. La implementación del modelo ARIMA permitió modelar adecuadamente la evolución temporal de la serie, obteniendo predicciones que siguen de forma consistente el comportamiento observado en los datos reales. Aunque el modelo presenta ligeras diferencias ante cambios bruscos en la popularidad de algunos videos, su desempeño general resulta satisfactorio para describir la tendencia predominante. A través del primer modelo (Random Forest Regressor), se determinó que predecir el volumen máximo de visitas basándose únicamente en metadatos iniciales presenta un alto grado de incertidumbre ($R^2 = 0.0401$), especialmente ante fenómenos virales extremos y caóticos que escapan de los patrones estándar. Por el contrario, el segundo modelo (Gradient Boosting) demostró una robustez significativamente mayor ($R^2 = 0.1614$) al predecir el tiempo de permanencia de un video en tendencias con un margen de error de apenas 3.37 días. Esto validó matemáticamente que el comportamiento y la velocidad de tracción que registra un contenido durante sus primeras 24 horas —siendo el volumen de visitas iniciales el factor predictivo más influyente— constituyen un indicador sólido y predecible para determinar la sostenibilidad de su éxito, posicionándose muy por encima de la profundidad de la interacción comunitaria.

Otro aspecto importante fue comprobar la utilidad de herramientas estadísticas como las funciones de autocorrelación, la prueba Dickey-Fuller y el análisis de residuos, ya que proporcionan evidencia objetiva para seleccionar un modelo apropiado y validar sus resultados. Desde una perspectiva práctica, este tipo de modelos puede ser utilizado para apoyar la toma de decisiones relacionadas con estrategias de publicación de contenido, análisis del comportamiento de audiencias o planificación de campañas digitales.

En conclusión, el proyecto demuestra que tanto las técnicas tradicionales de series temporales como los modelos avanzados de aprendizaje supervisado continúan siendo herramientas sólidas para el análisis de datos cronológicos, especialmente cuando se dispone de información histórica bien estructurada y se sigue una metodología adecuada de modelado.

References

- [1] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. *Time Series Analysis: Forecasting and Control*. 5th Edition, Wiley, 2015.
- [2] Hyndman, R. J., & Athanasopoulos, G. *Forecasting: Principles and Practice*. OTexts, 2018.
- [3] McKinney, W. Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 2010.
- [4] Harris, C. R., et al. Array Programming with NumPy. *Nature*, vol. 585, pp. 357–362, 2020.
- [5] Hunter, J. D. Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95, 2007.
- [6] Seabold, S., & Perktold, J. Statsmodels: Econometric and Statistical Modeling with Python. Proceedings of the 9th Python in Science Conference, 2010.
- [7] Dickey, D. A., & Fuller, W. A. Distribution of the Estimators for Autoregressive Time Series with a Unit Root. *Journal of the American Statistical Association*, 74(366), 427–431, 1979.
- [8] Kaggle. Trending YouTube Video Statistics Dataset. <https://www.kaggle.com/datasnaek/youtube-new>
- [9] Van Rossum, G., & Drake, F. L. *Python Reference Manual*. Python Software Foundation, 2009.
- [10] Google Developers. YouTube Data API v3 Documentation. <https://developers.google.com/youtube/v3>